



Tecnicatura Universitaria en Inteligencia Artificial

Procesamiento de Lenguaje Natural

Año 2026 · 2° semestre

Trabajo Práctico N° 2

“Embeddings y búsqueda semántica”

Integrantes:

Calabozo, Josías

Darruiz, Ismael

Di Carlo, Sebastián

Giuntoli, Sharo

1. Qué hicimos

Representamos las sinopsis de los 200 libros del TP1 (“Los más comentados” de Lectulandia) con cinco modelos y medimos cuál recupera mejor los libros relevantes para consultas en lenguaje natural:

Modelo	Tipo	Entrada
TF-IDF	Línea de base léxica	Texto limpio (minúsculas, sin puntuación ni stopwords)
Word2Vec propio	Promedio de vectores de palabra, entrenado con el corpus	Texto limpio
SBW (SBW-vectors-300-min5)	Promedio de vectores de palabra pre-entrenados	Texto limpio (el mismo que TF-IDF)
SBERT (distiluse-base-multilingual-cased-v1)	Modelo de oración	Texto crudo
E5 (multilingual-e5-small)	Modelo de oración, entrenado para búsqueda	Texto crudo, con prefijos `query:` y `passage:`

Evaluación: 13 consultas con sus libros relevantes (`queries.json`), escritas leyendo las sinopsis **antes** de correr cualquier ranking. Son de tres tipos: de trama, temáticas y sin palabras en común con sus libros relevantes (una de estas, en inglés). Medimos **precision@5** contra el piso de azar, que en cada consulta es `relevantes / 200`.

2. Resultados

	Azar	TF-IDF	W2V propio	SBW	SBERT	E5
Promedio (13 consultas)	0,027	0,385	0,277	0,323	**0,400**	**0,400**
De trama (5)	0,02	**0,40**	0,32	0,24	0,36	0,36
Temáticas (5)	0,04	**0,60**	0,40	0,44	0,44	**0,60**
Sin palabras en común (3)	0,02	0,00	0,00	0,27	**0,40**	0,13

3. ¿Cuánto mejor que TF-IDF? ¿Dónde gana y dónde no?

En promedio, los modelos de oración empatan con TF-IDF. La diferencia (0,400 contra 0,385) equivale a un solo libro acertado en 65 posiciones evaluadas. Consulta por consulta, SBERT y E5 le ganan a TF-IDF en 5, empatan en 4 y pierden en 4.

La diferencia está en el tipo de consulta:

- **Sin palabras en común, ganan los modelos semánticos.** TF-IDF saca 0 por construcción: si ninguna palabra coincide, el coseno es 0 con todos los libros. SBERT llega a 0,40. Con la consulta en inglés, *“a creepy mansion haunted by ghosts”*, SBERT encuentra *El misterio de Salem’s Lot* y *El cuento número trece*: el modelo multilingüe ubica la consulta cerca de sinopsis en español que dicen lo mismo.
- **Cuando la consulta comparte vocabulario con sus libros, TF-IDF es muy fuerte.** En “una historia de amor prohibido o imposible” saca 1,0, porque varias sinopsis dicen literalmente “amor prohibido”.

- **TF-IDF gana también con nombres propios y palabras raras.** Encontró en el puesto 1 la otra edición de cada uno de los cinco libros repetidos del corpus, aunque las dos sinopsis de *1984* casi no comparten texto: le alcanzó con palabras que casi no aparecen en otros libros, como *winston*, *partido* y *engranaje*.

4. Qué mide y qué no mide precision@5

- **Mide** si los primeros cinco resultados son relevantes, que es lo que ve un usuario.
- **No mide el orden** dentro de esos cinco.
- **No mide los relevantes que quedan afuera (recall).** Con 9 relevantes, un modelo puede sacar 1,0 aunque deje 4 sin encontrar.
- **Su máximo depende de cuántos relevantes tiene la consulta:** con 2, no puede superar 0,4.
- **Con 13 consultas es muy sensible:** cada acierto mueve el promedio 0,015, así que las diferencias de pocos centésimos entre modelos son ruido.
- **Los juicios de relevancia son nuestros** y tienen casos límite. En “una pandemia diezma a la población mundial”, SBERT y E5 ponen primero *Cadáver exquisito*, que excluimos porque el virus ataca a los animales y no a las personas. No cambiamos ese criterio después de ver los resultados.
- **El piso de azar es lo que da sentido a los números:** 0,40 es 15 veces el azar. Si una consulta tuviera la mitad del corpus como relevante, el mismo 0,40 apenas lo superaría.

5. Un caso donde la búsqueda falló

Consulta: “novelas sobre el amor por los libros y la lectura” (7 relevantes, como *La sombra del viento* y *La ladrona de libros*).

- **Resultado:** SBERT y E5 devuelven **solo novelas románticas** (*Como agua para chocolate*, *Yo antes de ti*, *After*). Su primer relevante aparece recién en el puesto 7. TF-IDF, en cambio, acierta 2 gracias a “libros”.
- **Hipótesis:** el modelo de oración representa la consulta completa, y su significado dominante es “amor”. En “el amor por los libros” el amor no es romántico, pero el corpus tiene muchas novelas románticas y esa región del espacio gana. Además, en las sinopsis relevantes el tema de los libros aparece mezclado con intriga e historia, y no domina el embedding.
- **Qué haríamos:** reformular sin la palabra ambigua (“novelas sobre bibliotecas, librerías y lectores”) o combinar el ranking léxico con el semántico.

Otro caso, en el que fallan todos: “un crimen misterioso en un lugar aislado del que nadie puede salir”. E5 devuelve historias de encierro (*El instituto*, *Maze Runner*). Las sinopsis relevantes nunca dicen “aislado”: dicen “el tren” detenido por la nieve, “un islote” o “una abadía”, y la relación con el aislamiento la hace el lector.

6. ¿Qué modelo elegiríamos para producción?

E5 (`multilingual-e5-small`), combinado con TF-IDF.

- **Rendimiento:** empata con SBERT en el promedio, y **casi no trunca**: su límite de 512 tokens corta 3 sinopsis, contra 178 de 200 (89 %) en `distiluse`. Con sinopsis más largas, esa diferencia pesaría más.
- **Costo:** corre en CPU, es chico (384 dimensiones) y los 200 embeddings se calculan en menos de un minuto. No hay costo por consulta.

- **Privacidad y dependencia de terceros:** se ejecuta localmente. Las consultas no salen a un servicio externo, y el modelo se descarga una sola vez y se puede guardar con el proyecto.
- **Reproducibilidad:** los pesos son abiertos y fijos. Con la misma versión, los vectores son siempre los mismos, a diferencia de una API que puede cambiar el modelo sin aviso.
- **Por qué combinarlo con TF-IDF:** los dos fallan en casos distintos. TF-IDF resuelve nombres propios y vocabulario literal, y E5 las paráfrasis. Por eso conviene combinar los dos rankings (búsqueda híbrida).

Descartamos los promedios de palabras. El **Word2Vec propio** no aprende significado con 200 sinopsis: los vecinos de “guerra” son *kaladin* o *radiantes*, palabras de una sola saga. Con **SBW**, todo se parece a todo: dos libros cualesquiera tienen una similitud de 0,89 ± 0,04.

7. Otros hallazgos

- **Truncado silencioso:** `distiluse` no avisa que corta el texto. Hay que tokenizar cada sinopsis para saberlo, y en las truncadas no ve, en promedio, el 39 % final.
- **El corpus de entrenamiento se nota:** en SBW, los vecinos de “familia” son familias biológicas (*Bochicidae*, *Eburia*), por los textos de especies con que se entrenó.
- **Espacios concentrados:** con E5, dos libros cualesquiera tienen una similitud de 0,82 ± 0,02. El orden relativo sirve, pero el valor absoluto no se puede usar como umbral de relevancia.
- **Los géneros vienen en orden alfabético** en el corpus: “el primer género” no es el principal, y no lo usamos como etiqueta.

8. Limitaciones

- **Corpus chico:** con 200 sinopsis, el Word2Vec propio no llega a aprender significado, y cada consulta tiene pocos relevantes (de 2 a 10).
- **Pocas consultas:** 13 consultas dan una evaluación ruidosa. Más consultas, y juicios de relevancia hechos por más de una persona, harían las comparaciones más confiables.

9. Uso de asistentes de IA

Usamos un asistente de IA para armar el código del notebook, redactar un primer borrador de `queries.json` (decidiendo la relevancia a partir de la lectura de las sinopsis y antes de correr los rankings) y redactar un primer borrador de las interpretaciones y de este informe. El grupo revisó las consultas, los juicios de relevancia, los resultados y las conclusiones, y es responsable de su contenido.